



UNIVERSIDAD
CATÓLICA
BOLIVIANA
SANTA CRUZ

Detección de Plantas Medicinales de Bolivia Mediante Aprendizaje Automático con YOLOv8

Docente: Msc. Edgar Jaldin Torrico

Estudiante: Nicole Lozada León

Fecha de entrega: 22 / 11 / 2025

Materia: Inteligencia Artificial

Santa Cruz, Bolivia
2025

Resumen

El conocimiento sobre las plantas medicinales en Bolivia forma parte fundamental del patrimonio cultural y de la medicina tradicional. Sin embargo, la correcta identificación de estas plantas puede ser un desafío para quienes no son expertos. Este trabajo presenta una metodología robusta y eficiente para la detección y clasificación de tres especies de plantas medicinales bolivianas de importancia regional: Romero (*Salvia rosmarinus*), Menta (*Mentha spicata*) y Eucalipto (*Eucalyptus globulus*), utilizando el algoritmo de detección de objetos YOLOv8 (You Only Look Once version 8).

El modelo se entrenó desde cero utilizando la arquitectura YOLOv8 Small en Google Colab con GPU T4, alcanzando un mAP50 superior al 80%. Los resultados demuestran que YOLOv8 es una herramienta viable y potente para desarrollar aplicaciones prácticas de detección múltiple que ayuden a la preservación y difusión del conocimiento en Bolivia.

Palabras Clave: Plantas Medicinales, Bolivia, YOLOv8, Deep Learning.

1. Introducción

Bolivia es uno de los 11 países con mayor diversidad de plantas superiores, donde incluye aproximadamente unas 5.000 especies exclusivas del país. Se conocen alrededor de 2.849 especies de plantas medicinales con identidad taxonómica verificada en los distintos herbarios del país de las cuales, los investigadores han evaluado cerca de 1.726 (Montes de Oca, 2005). Plantas como Romero, Menta y Eucalipto son ampliamente conocidas por sus propiedades curativas para tratar diversas dolencias.

Sin embargo, uno de los principales desafíos para el uso seguro y efectivo de estas plantas es su correcta identificación. La gran diversidad de especies y la similitud morfológica entre muchas de ellas —junto con la falta de conocimiento especializado— pueden conducir a confusiones con riesgos para la salud, como intoxicaciones o la ineficacia de los tratamientos (Carla Maldonado, 2020). Esta problemática limita el aprovechamiento de un recurso natural de incalculable valor cultural y terapéutico.

Con los avances en inteligencia artificial, particularmente en el campo de la visión por computadora, surgen nuevas oportunidades para abordar este problema de forma accesible y eficiente. Este estudio busca fusionar el conocimiento etnobotánico tradicional con técnicas modernas de detección de objetos, utilizando YOLOv8 para desarrollar un sistema capaz de identificar y localizar múltiples plantas medicinales bolivianas simultáneamente en una imagen.

A diferencia de los sistemas de clasificación tradicionales que solo pueden identificar una planta por imagen, YOLOv8 permite detectar múltiples instancias de diferentes especies en una misma escena, proporcionando además las coordenadas exactas de cada planta mediante bounding boxes. El potencial de esta investigación radica en crear una herramienta práctica accesible desde dispositivos móviles que pueda ayudar a las comunidades locales, estudiantes y al público general a identificar estas plantas de forma rápida y precisa en condiciones de campo.

2. Marco Teórico

2.1. Plantas Medicinales en Bolivia

En Bolivia, el uso de plantas medicinales está profundamente arraigado en la cultura y las tradiciones de sus pueblos. Constituye un componente esencial de la medicina tradicional, especialmente en comunidades indígenas y rurales donde el acceso a servicios de salud convencionales es limitado. Estas plantas no solo representan una alternativa terapéutica, sino que también forman parte de un sistema de conocimientos ancestrales transmitidos oralmente a través de generaciones. Su uso está ligado a visiones del mundo, rituales y prácticas culturales que reflejan la relación armónica entre el ser humano y la naturaleza. (Carla Maldonado, 2020)

Romero (*Salvia rosmarinus*)

El romero es un arbusto perenne originario de la región mediterránea, apreciado desde la antigüedad tanto por sus aplicaciones culinarias como medicinales (Gabriela Gallego, 2017). Perteneciente a la familia Lamiaceae y sus hojas, de forma lineal y aroma intenso, concentran la mayor parte de sus principios activos.

La investigación científica ha validado muchas de sus aplicaciones tradicionales. Su potente actividad antioxidante es una de sus características más estudiadas, atribuida a compuestos fenólicos como el ácido carnósico (Gabriela Gallego, 2017).



Fig, 1. Planta de Romero

Menta (*Mentha spicata*)

Comúnmente conocida como hierbabuena o menta verde, la *Mentha spicata* es una planta herbácea de la familia Lamiaceae, originaria de Europa y Asia, pero hoy extendida y cultivada en todo el mundo, incluyendo el continente americano. Es muy valorada por su característico aroma refrescante, debido a su alto contenido de mentol.

Su principal uso en la medicina popular está ligado al sistema digestivo. La infusión de sus hojas se consume para aliviar dolores de estómago, reducir la formación de gases (acción carminativa), calmar espasmos intestinales y como tónico general (Gabriela Gallego, 2017). También se emplea como analgésico suave en casos de dolor de cabeza y para aliviar síntomas del resfriado común.



Fig. 2. Planta de Menta

Eucalipto (*Eucalyptus globulus*)

El eucalipto es un árbol de gran porte, perenne y originario de Australia, perteneciente a la familia Myrtaceae. Se ha introducido en muchas regiones del mundo por su rápido crecimiento y el valor de su madera y aceite esencial. Sus hojas, especialmente las de los árboles jóvenes, son ricas en un aceite aromático con potentes propiedades medicinales.

La eficacia del eucalipto se debe a su principal componente activo, el 1,8-cineol (también llamado eucaliptol), que puede constituir hasta el 85% de su aceite esencial. Este compuesto ha demostrado tener una fuerte actividad antimicrobiana, expectorante y antiinflamatoria (Hernández Silva, 2014) . Su acción antiséptica

sobre las vías respiratorias es la propiedad más validada, lo que justifica plenamente su uso tradicional para combatir infecciones respiratorias y aliviar sus síntomas.



Fig. 3. Planta de Eucalipto

2.2. Detección de Objetos con Deep Learning

La detección de objetos es una tarea fundamental en visión por computadora que consiste en identificar y localizar objetos específicos dentro de una imagen. A diferencia de la clasificación simple, que solo determina qué objeto está presente, la detección proporciona además las coordenadas espaciales (bounding boxes) de cada instancia detectada, permitiendo identificar múltiples objetos simultáneamente.

Los algoritmos modernos de detección de objetos basados en redes neuronales convolucionales (CNN) han revolucionado este campo. Estas arquitecturas aprenden automáticamente características jerárquicas desde patrones simples (bordes, texturas) hasta conceptos complejos (formas de hojas, colores característicos), sin necesidad de ingeniería manual de features.

2.3. YOLO: You Only Look Once

YOLO (You Only Look Once) es una familia de algoritmos que revolucionó la detección de objetos al abordar el problema con un enfoque unificado y excepcionalmente rápido. A diferencia de métodos anteriores que requerían dividir el proceso en múltiples etapas (como proponer regiones y luego clasificarlas), YOLO procesa la imagen completa a través de una sola red neuronal. Este enfoque

radicalmente simple y unificado permite que YOLO sea hasta 1000 veces más rápido que sus predecesores basados en regiones, manteniendo una precisión comparable (Redmon et al., 2016). La arquitectura clave de YOLO radica en dividir la imagen de entrada en una cuadrícula y hacer que cada celda de la cuadrícula sea responsable de predecir simultáneamente las bounding boxes (cajas delimitadoras) y las probabilidades de clase para los objetos que contenga.

YOLOv8: Optimización y Versatilidad

YOLOv8, desarrollado por Ultralytics en 2023, representa la iteración más reciente y avanzada de esta familia de detectores en tiempo real. Esta versión incorpora múltiples optimizaciones arquitectónicas, incluyendo un backbone y neck mejorados que facilitan una extracción de características más eficiente, y la transición a la detección *anchor-free*, lo que elimina la necesidad de definir los tamaños de *anchor boxes* manualmente, simplificando la configuración y mejorando el rendimiento.

3. Metodología

3.1. Dataset de Plantas Medicinales Bolivianas

3.1.1. Captura de Imágenes

Para este estudio, se construyó un dataset propio y heterogéneo específicamente diseñado para detección de objetos. Las imágenes fueron capturadas utilizando la cámara de un iPhone desde una perspectiva cenital (vista desde arriba) a aproximadamente 15 cm de distancia de las plantas, en su mayoría. Esta configuración simula el escenario real de uso donde un usuario apuntaría su dispositivo móvil hacia plantas en mercados, jardines o entornos naturales.

3.1.3. Anotación de Datos con Roboflow

Para la tarea de detección de objetos, cada planta visible en las imágenes debe ser etiquetada con un bounding box (rectángulo delimitador) y su clase correspondiente.

La aumentación de datos incrementó el dataset efectivo a aproximadamente 3,756 imágenes, mejorando significativamente la capacidad del modelo para generalizar.

División del dataset:

- Entrenamiento: 80% (3,468 imágenes)

- Validación: 10% (142 imágenes)
- Test: 10% (146 imágenes)

3.2. Configuración y Proceso de Entrenamiento

El entrenamiento del modelo se basó en la arquitectura YOLOv8 Small (yolov8s.yaml), eligiendo esta variante por su óptimo equilibrio entre velocidad y precisión, ideal para el despliegue en hardware de recursos limitados.3.2.3. Hiperparámetros de Entrenamiento

El entrenamiento se rigió por un conjunto específico de hiperparámetros para maximizar la convergencia y evitar el sobreajuste. Se utilizó un tamaño de imagen de 640x640 píxeles (imgsz: 640) y un batch de 16. Para el proceso de optimización, se empleó el algoritmo Stochastic Gradient Descent (SGD) con una tasa de aprendizaje inicial (lr0) de \$0.01\$ y un momentum de \$0.937\$, complementado con una regularización L2 (weight_decay) de \$0.0005\$ para prevenir el *overfitting*.

4. Resultados

4.1. Métricas del Modelo

Curvas de Pérdida (Loss Curves)




Figura 4.1 Graficos de Entrenamiento y Validación

Fuente: Elaboración propia.

En la Figura 4.1, la primera fila muestra las pérdidas de entrenamiento (*train losses*), y la segunda fila (gráficos de la izquierda) muestra las pérdidas de validación (*val*

losses). El gráfico *train/box_loss* y *val/box_loss* (pérdida de la caja delimitadora) muestra cómo el modelo aprendió a localizar con precisión los objetos. El *train/cls_loss* y *val/cls_loss* (pérdida de clasificación) indica qué tan bien el modelo aprendió a clasificar las plantas. Se observa una rápida disminución en todas las curvas de pérdida en las primeras épocas, seguida de una tendencia a estabilizarse en valores bajos, lo que confirma que el modelo convergió satisfactoriamente tanto en los datos de entrenamiento como en los datos no vistos de validación.

Resultados del modelo

Métrica	Valor
mAP50	94.32%
mAP50-95	76.29%
Precision	93.95%
Recall	90.43%
F1-Score	92.16%

Tabla 4.1. Resultados del modelo

Fuente: Elaboracion propia

La tabla 4.1. presenta las métricas de rendimiento clave obtenidas por el modelo YOLOv8 Small después de su entrenamiento. La métrica principal, el mAP50, alcanzó un valor de 94.32%. Este alto porcentaje es muy significativo, ya que indica que el modelo es altamente efectivo en la localización de las cajas delimitadoras alrededor de las plantas. La métrica mAP50-95 se ubicó en 76.29%.

En cuanto a las métricas de clasificación, la Precision fue de 93.95%, lo que significa que de todas las detecciones que hizo el modelo, casi el 94% fueron correctas. El Recall fue de 90.43%, indicando que el modelo logró identificar a más del 90% de todas las plantas reales presentes en las imágenes. El F1-Score, que es la media armónica de ambas, se estableció en 92.16%, confirmando un excelente equilibrio entre las detecciones correctas y la capacidad de encontrar todos los objetos.

Precisión por cada clase

Clase	AP50 (%)
Eucalipto	70.79%
Menta	80.91%
Romero	77.19%

Tabla 4.2.. Precisión por Clase

Fuente: Elaboracion propia

En la tabla 4.2., el análisis de la precisión desglosada por clase revela diferencias en el rendimiento del modelo para cada especie de planta. La menta fue la clase con la precisión más alta, alcanzando un AP50 de 80.91%, lo que sugiere que sus características morfológicas la hicieron la más fácil de identificar y localizar correctamente. Por otro lado, el eucalipto mostró el rendimiento más bajo con un AP50 de 70.79%, una diferencia significativa con respecto a la menta, lo que podría deberse a la variabilidad en la forma de sus hojas o su apariencia en el *dataset*. El romero se ubicó en un punto intermedio, logrando un AP50 de 77.19%. En conjunto, estos valores indican que si bien el modelo es funcional para todas las clases, existen oportunidades de mejora a través de la expansión del *dataset*, particularmente para la clase eucalipto, para lograr una uniformidad de rendimiento.

4. Conclusión

Este trabajo demuestra la viabilidad de utilizar herramientas de aprendizaje automático de alto nivel, como YOLOv8, para la clasificación de plantas medicinales de Bolivia. Se desarrolló con éxito un modelo capaz de diferenciar entre tres especies importantes con una alta precisión.

El enfoque propuesto abre un abanico de posibilidades para la creación de herramientas tecnológicas con impacto social. Este modelo podría ser la base para futuras investigaciones de expertos, promoviendo así la conservación del conocimiento ancestral y el uso seguro de los recursos naturales.

Como trabajos futuros, se propone ampliar el dataset para incluir imágenes en una mayor variedad de estaciones y etapas de crecimiento de la planta para hacer el modelo aún más robusto.

5. Referencias

- Carla Maldonado. (2020, April 23). *La importancia de las plantas medicinales, su taxonomía y la búsqueda de la cura a la enfermedad que causa el coronavirus (COVID-19)*. SciELO Bolivia. Retrieved October 10, 2025, from http://www.scielo.org.bo/scielo.php?script=sci_arttext&pid=S1605-25282020001000001
- Gabriela Gallego, M. (2017). Estudio de la actividad antioxidante de diversas plantas aromáticas y/o comestibles. *Tesis doctoral, Universitat Politècnica de Catalunya*.
- Hernández Silva, J. M. (2014, Octubre 14). *Evaluación de la acción bactericida de aldehído cinámico y aceite esencial de eucalipto (Eucalyptus spp.) en emulsión*.
- Montes de Oca, I. (2005). *Enciclopedia geográfica de Bolivia*. Editora Atenea.
- Nair B J, B., & Balasubramanian, A. (2024, Febrero). *Classification of Indian Medicinal Flowers using MobileNetV2*. 10.23919/INDIACom61295.2024.10498274.
- Tejero MR, G.-., Porcel M, C., & Rojas CP, S. (2007, Diciembre 17). *Medicinal plants in the Mediterranean area: synthesis of the results of the project Rubia*.

6. Anexos:

Código General del Google Colab:

https://colab.research.google.com/drive/1lgqJPapApwFNN7I_BarxTwKYu72TbV8Y?usp=sharing

Código específico del modelo en Google Colab:

```
# CELDA 6: CONFIGURAR HIPERPARÁMETROS DE ENTRENAMIENTO
```

```
# Configuración de entrenamiento
```

```
TRAINING_CONFIG = {  
    'epochs': 100,  
    'imgsz': 640,  
    'batch': 16,  
    'patience': 50,  
    'save_period': 10,  
    'workers': 8,  
    'pretrained': False,  
    'optimizer': 'SGD',  
    'lr0': 0.01,  
    'momentum': 0.937,  
    'weight_decay': 0.0005,  
    'cos_lr': True,  
}
```

```
print("⚙️ Configuración de entrenamiento:")  
for key, value in TRAINING_CONFIG.items():  
    print(f" {key}: {value}")
```

```
# Nombre único para esta ejecución
```

```
RUN_NAME = f"plantas_bolivia_{datetime.now().strftime('%Y%m%d_%H%M%S')}"  
print(f"📝 Nombre de la ejecución: {RUN_NAME}")
```

```
# CELDA 8: ENTRENAR EL MODELO
```

```
# ENTRENAR
```

```
results = model.train(  
    data=DATASET_YAML,  
    epochs=TRAINING_CONFIG['epochs'],  
    imgsz=TRAINING_CONFIG['imgsz'],  
    batch=TRAINING_CONFIG['batch'],  
    patience=TRAINING_CONFIG['patience'],  
    save_period=TRAINING_CONFIG['save_period'],  
    workers=TRAINING_CONFIG['workers'],  
    pretrained=TRAINING_CONFIG['pretrained'],  
    optimizer=TRAINING_CONFIG['optimizer'],  
    lr0=TRAINING_CONFIG['lr0'],
```

```

momentum=TRAINING_CONFIG['momentum'],
weight_decay=TRAINING_CONFIG['weight_decay'],
cos_lr=TRAINING_CONFIG['cos_lr'],
name=RUN_NAME,
project='/content/runs/detect',
exist_ok=True,
verbose=True,
device=0, # Usar GPU 0
)

```

```

print("\n" + "="*80)
print("✅ ENTRENAMIENTO COMPLETADO")
print("="*80)

```

Muestra del conjunto de datos de prueba:

